تحليل أداء موظفي مركز الاتصال

Call Center Agent Performance Analysis

أحمد المطيري

تقييم Maharah GDP · نوفمبر 2026

المطلوب لكل مكالمة

- **المتحدثون:** مَن Customer ومَن Agent
- **النص:** كل الكلام بالترتيب مع الوقت
- **الملخص:** المشكلة، والإجراء، والنتيجة
- **المشاعر:** التصنيف، والسبب، واقتباس من العميل
- **الملاحظات:** نسب الخطأ والقيود

بدون أي paid API: كل الـ models تعمل داخل الـ notebook، فلا تخرج بيانات المكالمات منه.

```
{
  "call_id": "08f360b3f3b844ef",
  "speakers": {"Speaker 1": "Customer",
               "Speaker 2": "Agent"},
  "transcript": [ ... 12 turns ... ],
  "summary": { issue, action, outcome },
  "sentiment": {"label": "positive", ...},
  "notes": [ ... ]
}
```

سجل من results/calls.json (مختصر)

البحث عن البيانات: 12 مجموعة و 8 أوراق بحثية

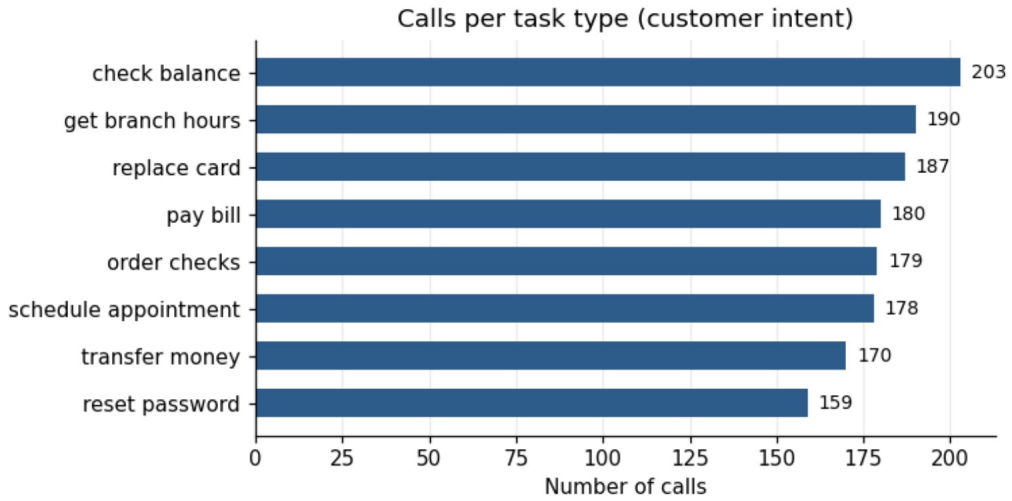
أغلب البيانات الحقيقية لمراكز الاتصال إما بدون صوت، أو بدون نص، أو مدفوعة. أمثلة من الجدول:

البيانات	السبب
HarperValleyBank	صوت + نص بشري + ترخيص CC BY 4.0 ← المختارة
CallCenterEN (92 ألف مكالمة حقيقية)	الصوت غير منشور بسبب الخصوصية
InfoBayAI Arabic Call Center	صوت بدون نصوص للمقارنة
AxonData Call Center	11 تسجيل فقط في العينة المجانية
ABCD	محادثات نصية بدون صوت
Switchboard / Fisher	ليست خدمة عملاء، والترخيص مدفوع

الجدول الكامل مع الروابط والتراخيص والشروط في research/dataset_survey.xlsx

البيانات المختارة: HarperValleyBank

- 1,446 مكالمة بنكية، 23.7 ساعة، وترخيص CC BY 4.0
- ملف صوت لكل متحدث، ونص مكتوب من بشر (للتقييم فقط)
- مكالمات تمثيلية (simulated)، وليست عملاء حقيقيين
- **مشكلة في البيانات:** في 37 مكالمة صوت الموظف محفوظ في مجلد caller، فربطت كل ملف بالـ channel ثم بالدور، وتحققت من المحتوى
- **العينة:** 25 مكالمة، 3 من كل نوع مع seed ثابت (42)، ومكالمة من الـ 37



عدد المكالمات لكل نوع مهمة (notebook 01)

خطوات العمل: 6 notebooks بالترتيب

#	الخطوة	الأداة	يعمل على
01	فحص البيانات واختيار العينة	pandas, matplotlib	اللابتوب
02	تحويل الصوت إلى نص	faster-whisper medium.en	Colab T4
03	فصل المتحدثين	القناة ← الدور، الكلمات ← turns	اللابتوب
04	الملخص	Qwen3-4B-Instruct	Colab T4
05	مشاعر العميل	Qwen3-4B-Instruct + RoBERTa	Colab T4
06	التحقق والنتائج	فحوصات + calls.json	اللابتوب

النصوص المرجعية في البيانات استُخدمت للتقييم فقط، وليست مخرجاً للمشروع.

تحويل الصوت إلى نص: WER = 4.9%

اختيار النموذج (3 مكالمات)

النموذج	WER
small.en	4.7%
medium.en ← المختار	2.9%
large-v3	4.3%

التشغيل النهائي (25 مكالمة)

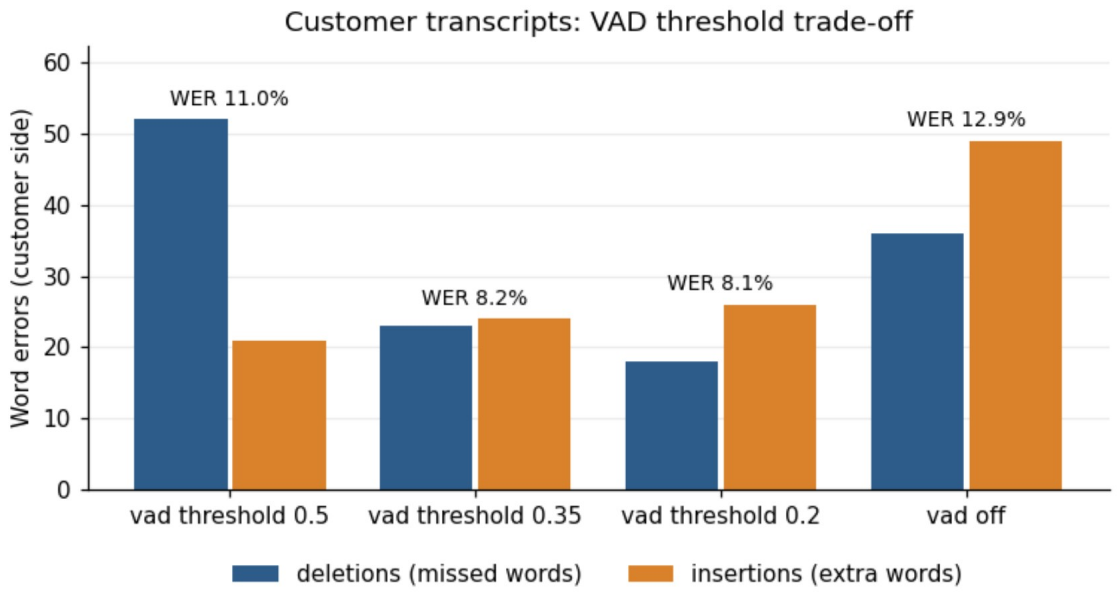
المتحدث	نموذجنا	ASR الموجود في البيانات
الإجمالي	4.9%	7.5%
الموظف	2.9%	6.9%
العميل	8.1%	8.5%

- نسبة WER = الكلمات الخاطئة ÷ كلمات النص المرجعي
- قبل الحساب وحّدت النص في الطرفين: الأرقام كلمات، وأرقام الجوال رقماً رقماً، وحذف كلمات الحشو
- السرعة: أسرع من الزمن الحقيقي بحوالي 50 مرة على T4

أسوأ مكالمة: صوت العميل منخفض جداً

- المكالمة c0940816: نسبة WER للعميل 81.8%، وأغلب الأخطاء كلمات ناقصة
- السبب: الـ VAD احتفظ بـ 31% فقط من كلام العميل
- خفض الـ threshold يقلل الكلمات الناقصة، وإيقافه يزيد الكلمات الزائدة
- اخترت 0.2: العميل 8.1% بدل 11.0%، والمكالمة نفسها 9.1%

ملاحظة: اخترت القيمة على نفس الـ 25 مكالمة، فالنتيجة متفائلة قليلاً.



الكلمات الناقصة مقابل الزائدة حسب الـ threshold (notebook 06)

فصل المتحدثين: كل متحدث له channel

- القناة 1 هي Speaker 1، والقناة 2 هي Speaker 2، فلا حاجة لـ diarization model
- الأدوار من الـ metadata، مع التحقق من المحتوى: الموظف وحده يقول ترحيب البنك
- سكتة أطول من ثانية تبدأ جملة جديدة، والجمل مرتبة بالوقت
- **النتائج:** 99.4% من الكلمات في مكانها الصحيح، والأدوار صحيحة في 22 من 22، و 55 من 237 turn فيها تداخل

Speaker 2 · Agent · 1.8 s

Hello, this is Harbor Valley National Bank. My name is Robert. How can I help you today?

Speaker 1 · Customer · 10.9 s

Hi. My name is Linda Smith. I need to check my account balance.

Speaker 2 · Agent · 42.2 s

Your checking account balance is $90 exactly.

Speaker 1 · Customer · 49.8 s

Fantastic. That's all I needed.

مقتطف من نص المكالمة 08f360b3 كما أخرجه notebook 03

الملخصات: 8 من 10 دقيقة

- النموذج Qwen3-4B-Instruct يخرج JSON بثلاث حقول: المشكلة، والإجراء، والنتيجة
- فحوصات تلقائية على 25 مكالمة: الصيغة صحيحة 25/25، والمشكلة تطابق نوع المهمة 25/25، ولا يوجد رقم غير موجود في النص
- مراجعة يدوية لـ 10 مكالمات: 8 دقيقة، و 9 كاملة
- **خطأ (9e05bd9c):** التسجيل ينقطع بعد سؤال العميل، لكن الملخص يقول إن الموظف أعطاه أوقات الفرع، وهذا hallucination
- الحل القادم: كشف المكالمات الناقصة، وطلب اقتباس لكل حقل

customer_issue

The customer wanted to check her checking account balance.

agent_action

The agent confirmed the customer's identity and provided her checking account balance of $90.

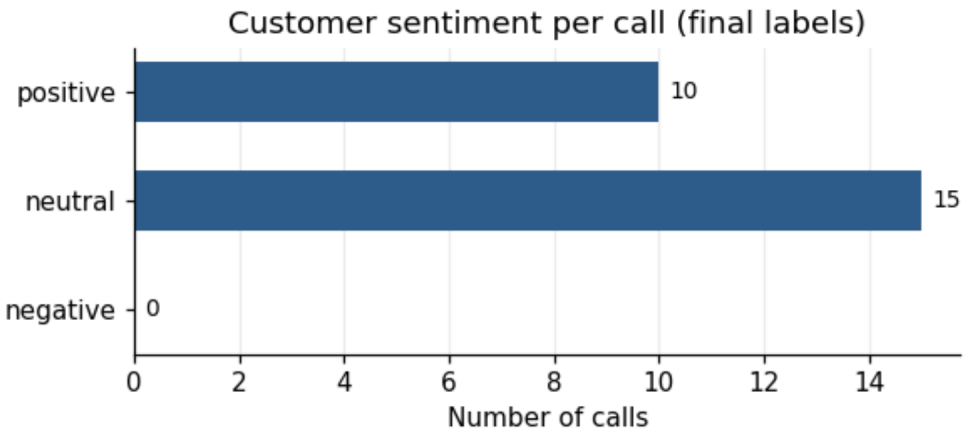
outcome

The customer expressed satisfaction and stated there was nothing else needed.

ملخص المكالمة 08f360b3 كما أخرجه notebook 04

مشاعر العميل: 9 من 10 صحيحة

- النموذج يقرأ المكالمة كاملة ويعطي التصنيف والسبب واقتباساً من كلام العميل
- الاقتباس يُفحص تلقائياً: حقيقي في 24 من 25 مكالمة
- نموذج RoBERTa رأي ثانٍ لكل جملة: 12 مكالمة تحسّنت من البداية للنهاية، و 13 بقيت كما هي، ولا شيء ساء
- اختبار النفي: "no problem" صُنّفت neutral (صحيح)، و "i lost my debit card" صُنّفت negative (خطأ: حدث وليس شعوراً)
- لا يوجد عميل سلبي في العينة، فالتصنيف السلبي لم يُختبر على مكالمات حقيقية



التصنيف النهائي لـ 25 مكالمة (notebook 06)

08f360b3 · positive

evidence: “Fantastic. That's all I needed.”

التحقق والقيود

كيف تم التحقق

- حساب WER مقارنة بنصوص مرجعية كتبها بشر
- فحوصات تلقائية على كل الـ 25 مكالمة
- مراجعة يدوية لـ 10 مكالمات في كل مهمة، مع Wilson 95% CI
- إعادة تشغيل notebook 02 أعطت نفس الأرقام
- كل مكالمة فيها كل الحقول المطلوبة في calls.json

القيود

- مكالمات تمثيلية، والصوت الحقيقي أصعب
- العينة صغيرة: 8 من 10 تعني ما بين 49% و 94%
- قيمة الـ VAD threshold اختيرت على نفس الـ 25 مكالمة
- لا يوجد عملاء سلبيون في العينة
- الاتفاق بين النماذج (64% إلى 84%) ليس دقة

الدروس والخطوات القادمة

ماذا تعلمت

- أفحص البيانات قبل أن أثق بها: 37 مكالمة كان صوت الموظف فيها في مجلد caller
- أقرأ أسوأ حالة قبل تغيير النموذج: مكالمة هادئة واحدة قادت لتعديل الـ VAD
- الـ language models تملأ الفراغات من عندها، فلا بد من دليل يُفحص

الخطوات القادمة

- التجربة على مكالمات حقيقية
- كشف المكالمات الناقصة وكتابة «not stated»
- إضافة اقتباسات إلى الملخصات
- قياس أداء الموظف من سجلات المكالمات

شكراً لكم

github.com/ahmedalmoutiry-wq/call-center-agent-performance-analysis